

Detección Temporal multimodal de Emociones y Atención

Presentación de Avances

Junio, 2026

Contexto

Tema:

Deteccion de emociones y nivel de interes con eye-tracking, GSR, EEG y expresiones faciales en navegacion web.

Antecedente:

Trabajos previos muestran buen desempeno por modalidad, pero con limitaciones al capturar la dinamica temporal.

Limitaciones actuales:

Perdida de dinamica temporal (resumen por promedios/medianas).
Fusion multimodal tardia, con mejoras potencialmente marginales

Oportunidades:

Modelo multimodal temporal que siga la evolucion de atencion y emociones.
Tratar atencion y emociones como procesos dinamicos.
El aporte principal esta en la temporalidad, tipo de fusion y agregar variables

Hipotesis



- 01 H1: Los modelos temporales multimodales superan a los modelos estaticos en la deteccion de emociones y atencion.
- 02 H2: Los modelos temporales multimodales permiten capturar fenomenos de fatiga y habituacion durante la navegacion web

1. Comportamiento del usuario como fenómeno dinámico

- La atención y las respuestas emocionales varían continuamente durante la interacción con un estímulo.
- Su análisis requiere considerar la evolución temporal de las señales observadas.

2. Naturaleza multimodal de los estados cognitivos y emocionales

- El estado del usuario se manifiesta a través de múltiples canales fisiológicos y conductuales.
- Cada modalidad aporta información complementaria sobre procesos de atención, interés y emoción.

3. Fusión multimodal

- La integración de distintas fuentes de información permite obtener una representación más completa del usuario.
- La literatura distingue estrategias de fusión temprana, intermedia y tardía.

4. Modelamiento temporal

- Los modelos temporales permiten capturar dependencias entre observaciones consecutivas.
- Facilitan la identificación de patrones como habituación, fatiga y transiciones entre estados cognitivos y emocionales.

Panorama y tendencia


Paper	Señales	Arquitectura	Principal aporte
TACOformer (2023)	EEG + GSR + ECG	Cross-Attention Transformer	Atención conjunta token-canal; SOTA en DEAP y DREAMER
Feng et al. (2025)	EEG + Facial	Multi-Head Self-Attention	Fusión adaptativa EEG-Facial (81.1% en MED-HI)
Milmer (2025)	EEG + Facial	Swin Transformer + Cross-Attention	Modelado temporal sobre secuencias faciales (96.7% en DEAP)
Wang et al. (2025)	EEG + Eye-Tracking	Cross-Modal Attention	Alineación entre actividad cerebral y movimiento ocular (90.6% en SEED-IV)
MuMTAffect (2025)	Gaze + Pupila + AU + GSR	Transformers por modalidad	Aprendizaje multitarea para emoción y personalidad
GBV-Net (2025)	EEG + GSR + ECG + Facial	Fusión jerárquica con compuertas	Integración profunda de señales visuales y fisiológicas

Emociones

Dos grandes enfoques:

Discreto (Ekman): 6 emociones básicas.

Dimensional (Russell): valencia-arousal.




Modelo discreto (Ekman)
6 emociones básicas universales

Reconocibles transculturalmente (FACS)




Estrategias de Fusión Multimodal



La ganancia multimodal depende de la arquitectura de fusion, no solo de agregar modalidades.
Zali-Vargahan et al. (2023): 95.3 % con fusion CNN+Stockwell (EEG+fisio+facial). Saavedra (2024): sin mejora significativa con fusion tardia EEG+GSR en contexto web

Modelamiento temporal


LSTM / GRU



TCN



Transformer Temporal



Referencias clave por arquitectura

LSTM: Saffie (2023) — EEG web. TCN: Bai et al. (2018); Kamrud et al. (2021) — EEG; Elmadjian et al. (2022) — eye-tracking. Transformer: Vaswani et al. (2017); MNT (2022) — EEG+PPG+GSR; TERE (2025) — EEG+eye-tracking

Brechas y Aportes

Brechas en la literatura

1. Senales tratadas como vectores estaticos, sin dinamica temporal
2. Fusion de 4 señales en contexto web: inexistente
3. Fatiga y habituacion no modeladas como variable de interes
4. Sin ablation studies sistematicos

Aporte de esta tesis

- ✓ Modelos secuenciales EEG+GSR+Eye+Facial.
- ✓ Comparacion early / intermediate /late fusion.
- ✓ Deteccion de fatiga y habituacion (H2).
- ✓ Ablation study por modalidad y temporalidad.
- ✓ Baseline estatico como control.

Preprocesamiento EEG: Filtrado y Calidad

Adquisición

OpenBCI Cyton — 16 canales, 250 Hz, 24-bit ADC

Señal hex $\rightarrow \mu\text{V}$ ($V_{\text{ref}} = 4.5\text{V}$, Gain = 24)

Filtrado (Butterworth ord. 4, fase cero)

Pasa-altos 1 Hz $\rightarrow$ elimina drift DC

Pasa-bajos 40 Hz $\rightarrow$ elimina EMG

Notch 50 Hz $\rightarrow$ elimina interferencia de red eléctrica


Calidad y artefactos

Muestras $> \pm 150 \mu\text{V}$ $\rightarrow$ descartadas

Canales clasificados:

✓ bueno / ⚠ plano / ✗ ruidoso

Solo canales buenos ingresan al modelamiento




Preprocesamiento EEG: Segmentación

Segmentación

Extracción de características EEG

- Estimación espectral mediante método de Welch
- Cálculo de potencia en bandas
- Potencia absoluta y relativa por canal
 - Construcción de índices inter-banda θ/α , θ/β , α/β , $\beta/(\alpha+\theta)$, etc.
- Cálculo de asimetría hemisférica Alpha
- Generación del vector de características neurofisiológicas

Banda	Nombre	Rango de	Potencia
δ	Delta	0.5 – 4 Hz	Absoluta y relativa
θ	Theta	4 – 8 Hz	Absoluta y relativa
α	Alpha	8 – 13 Hz	Absoluta y relativa
β	Beta	13 – 30 Hz	Absoluta y relativa
γ	Gamma	30 – 40 Hz	Absoluta y relativa



Preprocesamiento EEG: Features

Potencia por banda (PSD método Welch)


Features espectrales por época

- Potencia absoluta y relativa en 5 bandas: δ , θ , α , β , γ
- 7 índices inter-banda: θ/α (carga cognitiva), engagement, fatiga, relajación, atención...
- Asimetría hemisférica alpha $\rightarrow$ valencia emocional
- $\times 16$ canales = 273 features por época

Resultado:

tensor: $N_{\text{épocas}} \times N_{\text{canales}} \times 500$ muestras

Índice	Fórmula
Carga cognitiva	θ / α
Déficit atencional	θ / β
Relajación	α / β
Engagement	$\beta / (\alpha + \theta)$
Fatiga mental	$(\alpha + \theta) / \beta$
Ondas lentas	$(\delta + \theta) / (\alpha + \beta)$
Alto nivel cognitivo	$\gamma / (\delta + \theta)$



Eye-tracking

- Numero de fijaciones
- Duracion promedio de fijaciones
- Amplitud y velocidad de sacadas
- Dispersión de la mirada
- Diametro pupilar promedio

GSR

- Numero de picos (SCR)
- Amplitud de respuesta
- Nivel tonico (SCL)
- Variabilidad de la senal

EEG

- Potencia por bandas (delta, theta, alpha, beta, gamma)
- Relaciones entre bandas

Expresion facial


- Embeddings faciales
- Probabilidades de emocion (FaceReader)

Caracterización del conjunto de datos

Fuente: Toma de Muestras 2 - EGG raw

Resultados principales

- 48 participantes registrados.
- 16 canales EEG por participante.
- Duración promedio de las grabaciones: $13,4 \pm 1,5$ minutos.
- Duración mediana: 13,1 minutos.
- No se detectaron valores faltantes (NaN = 0).





Evaluación de la calidad de la señal

Se realizó un análisis de calidad considerando:

- detección de canales saturados,
- inspección visual de la señal EEG,
- análisis espectral mediante PSD (Welch).

Resultados

- 21 de 48 participantes presentan al menos un canal saturado.
- La mediana es 0 canales saturados, indicando que más de la mitad de los registros no presenta saturación.
- El promedio es 1 canal saturado por participante, concentrado en un grupo reducido de sujetos.



Observaciones

Se identificó un pico de potencia cercano a 50 Hz, atribuible al ruido de la red eléctrica, por lo que será necesario incorporar un filtro notch durante el preprocesamiento.

Implicancias para el desarrollo

Decisiones metodológicas

A partir de estos resultados se implementará un pipeline de preprocesamiento que incluirá:

- Filtro pasa banda.
- Filtro notch (50 Hz).
- Tratamiento de canales saturados.
- Segmentación en ventanas para extracción de características.

Dataset Esperado:

Participante	Ventana	Características EEG	Etiqueta
P01	0-2 s	PSD, bandas, índices	Atento
P01	1-3 s	PSD, bandas, índices	Atento
P01	2-4 s	PSD, bandas, índices	No atento



Atencion: Construcción Etiqueta.

Para entrenar un modelo supervisado, se necesita que cada venta tenga asociada una etiqueta. Actualmente no existe esta variable en el ds.

Dataset objetivo:

Participante	Estimulo	Ventana	Atención
P01	web1	1	alta
P01	web2	2	media
P02	web1	1	baja

Definicion Nivel de Anteción

Se va a utilizar una fuente como **pseudo ground truth**.

Enfoque 1: Eye Tracking

Generar un indice de atención cn reglas fisiologicas.

- duración de fijaciones;
- número de fijaciones;
- mirada dentro de áreas de interés;
- pérdida de mirada;
- dilatación pupilar.

Enfoque 2: Expresion facial

Generar un indice de atención con un modelo profesor.

- Similar a Subiabre, generar un clasificador facial, que entregue etiqueta de atención, para que luego otro modelo aprenda de esas etiquetas.

Enfoque 3: Estimación Multimodal

Generar un indice de atención en base a N señales.

- Utilizar Eye Tracking + Expresiones faciles y generar un Attention Score y discretizarlo para cada persona.

Limitaciones: El modelo nunca podra ser mejor que las etiquetas que recibe.

Sentimiento

1. Completar el preprocesamiento y sincronización temporal de señales.
2. Construir características por modalidad desde un baseline: faciales, oculares, GSR, EEG.
3. Probar predicciones unimodales para cada modalidad por separado.
4. Evaluar predicciones multimodales con distintas combinaciones.

Atención

1. Completar el preprocesamiento y sincronización temporal de señales.
2. Definir la etiqueta de atención (usando Eye Tracking y/o rostro).
3. Segmentar todas las señales en ventanas de tiempo.
4. Entrenar un modelo que prediga atención usando solo EEG.
5. Evaluar qué tan bien predice la atención.

Eye-Tracking: fijaciones, sacadas y mapa de calor



GSR (Respuesta Galvánica): señal y componentes

